

PRD (Product Requirements Document)

Certi-GPT: nano-vLLM 기반 정보처리기사 맞춤형 학습 비서

1. 제품 개요 (Product Overview)

1.1 제품명: Certi-GPT

1.2 비전 (Vision)

RTX 4070급 로컬 GPU 환경에서 한국어 소형 언어 모델(sLM)을 직접 구동하고, 이를 기반으로 정보처리기사 시험 대비 AI 학습 플랫폼을 구축한다. 단순한 "LLM 활용 서비스"가 아니라,

- 추론 엔진(nano-vLLM) 직접 구축
- 양자화(4-bit) 및 메모리 최적화 실험
- PagedAttention 기반 성능 분석
- RAG 기반 개념 강화 시스템 설계

까지 경험하는 AI 시스템 엔지니어링 중심 캡스톤 프로젝트를 목표로 한다.

2. 문제 정의 (Problem Statement)

2.1 기존 문제점

- 정보처리기사 학습은 여전히 PDF, 기출문제집 중심의 정적 학습 방식에 의존.
- 학생들은 LLM을 사용하더라도:
 - OpenAI API 등 외부 서비스 의존
 - 추론 엔진 내부 구조 이해 부족
 - GPU 메모리 구조 및 KV Cache 개념 미이해
- AI를 "사용자"로 머물 뿐 "엔진을 구축하는 개발자" 경험 부족

3. 목표 (Goals & Success Metrics)

3.1 핵심 목표

구분	목표
G1	RTX 4070 8GB 환경에서 8B~10B 한국어 sLM 안정적 구동
G2	4-bit Quantization 적용 및 메모리 사용량 분석

- G3 RAG 기반 정보처리기사 해설 생성
- G4 PagedAttention 성능 튜닝 실험
- G5 웹 기반 학습 서비스 완성

3.2 성공 지표 (KPIs)

지표	목표
Token Per Second (TPS)	15~30 TPS 이상
VRAM 사용률	85% 이하 안정적 동작
오답 해설 정확도	주관 평가 80% 이상
동시 사용자 처리	3~5명 이상 테스트 성공
오답 노트 자동 생성 성공률	95% 이상

4. 타겟 사용자 (Target Users)

- 정보처리기사 준비생 (대학생, 취업생)
- AI 시스템을 배우는 컴퓨터공학 전공자
- LLM 엔지니어링에 관심 있는 학생

5. 핵심 기능 요구사항 (Functional Requirements)

5.1 AI 문제 풀이 기능

FR-1: 객관식 문제 풀이

- 사용자가 문제 입력
- 모델이 정답 선택 + 이유 설명
- 정답률 로그 저장

FR-2: 서술형 개념 설명

- 특정 개념 요청 시 단계적 설명
- 예시 포함

5.2 RAG 기반 해설 강화

FR-3: 오답 발생 시 개념 검색

- ChromaDB 기반 벡터 검색
- 관련 PDF/기출 요약 검색
- LLM이 검색 결과를 기반으로 해설 생성

FR-4: 출처 기반 답변 표시

- 참고 개념 출처 요약 표시
-

5.3 학습 관리 기능

FR-5: 오답 노트 자동 생성

- 틀린 문제 자동 저장
- 개념 요약 자동 생성
- Markdown 파일로 export 가능

FR-6: AI 감독관 모드

- 실제 시험 모드 (시간 제한)
 - 시험 종료 후 자동 채점
 - 취약 영역 분석 리포트 생성
-

5.4 시스템 엔지니어링 실험 기능

FR-7: VRAM 사용량 모니터링

- 모델 로딩 시 VRAM 계산
- KV Cache 메모리 계산 수식 제공


FR-8: PagedAttention 튜닝 실험

- Block size 변경
 - TPS 비교 그래프 출력
-

6. 비기능 요구사항 (Non-Functional Requirements)

항목	요구사항
성능	1초 이내 응답 시작
안정성	1시간 이상 지속 동작
확장성	모델 교체 가능 구조
유지보수	모듈화 설계

7. 시스템 아키텍처



8. 기술 스택

Hardware

- NVIDIA RTX 4070 (8GB VRAM)
- 16GB RAM 이상

Engine

- nano-vLLM

Model 후보

- MLP-KTLim 의 Llama-3 Korean Blossom 8B
- Yanolja 의 EEVE-Korean-Instruct-10.8B

Backend

- Python 3.10+
- FastAPI
- ChromaDB

Frontend

- Gradio
-

9. 단계별 개발 일정 (6주 계획)

Week 1-2: 인프라 구축

- CUDA + PyTorch 설치
 - 4-bit Quantization 적용
 - VRAM 사용량 분석 실험
 - KV Cache 메모리 계산 보고서 작성
-

Week 3-4: RAG 엔진 구현

- 기출 문제 JSON 정리
 - PDF → 텍스트 변환
 - ChromaDB 벡터화
 - 프롬프트 엔지니어링
-

Week 5: 웹 서비스 통합

- FastAPI 연동
 - Gradio UI 구축
 - 실시간 채팅 인터페이스 구현
-

Week 6: 성능 최적화 및 실험 보고서

- PagedAttention 블록 사이즈 변경 실험
 - TPS 측정
 - GPU 메모리 비교표 작성
 - 최종 발표 자료 제작
-

10. 교육적 가치

10.1 단순 LLM 사용을 넘는 학습

학생들은 다음을 직접 경험하게 된다:

- LLM 파라미터 수에 따른 VRAM 계산
 - Quantization 전/후 비교
 - KV Cache 메모리 구조 이해
 - PagedAttention 작동 원리 실험
 - 로컬 LLM 서비스 운영
-

10.2 엔지니어링 관점 성장

이 프로젝트는 단순한 챗봇 제작이 아니라:

“LLM 추론 엔진을 이해하고, 최적화하고, 실험하고, 서비스로 만드는 경험”

을 제공한다.

11. 확장 가능성 (Future Roadmap)

1. 멀티 GPU 확장 실험
 2. LoRA 기반 도메인 미세튜닝
 3. 모바일 클라이언트 연동
 4. Raspberry Pi 경량 AI 디바이스화
 5. 다른 자격증(컴활, SQLD 등)으로 확장
-

12. 최종 산출물 (AI 시스템 엔지니어링 캡스톤 프로젝트)

1. 동작하는 웹 서비스
2. 시스템 설계 문서
3. 성능 비교 리포트
4. GPU 메모리 분석 보고서
5. GitHub 공개 저장소

결론

Exam-GPT는 단순한 AI 학습 서비스가 아니다.

- 로컬 GPU 기반 AI 시스템 구축
- 한국어 sLM 활용
- 추론 엔진 내부 최적화 경험
- RAG 기반 실전 학습 플랫폼 구현

을 통합한 AI 시스템 엔지니어링 캡스톤 프로젝트다.

원하시면 이 PRD를 기반으로:

-  발표용 PPT 구조
-  성능 실험 설계 문서
-  GitHub README 템플릿
-  폴더 구조 설계안

까지 구체적으로 확장해 드릴 수 있습니다.

RTX 4070의 8GB VRAM은 **Llama-3-8B-Instruct(4-bit Quantized)**나 **EEVE-Korean-10.8B** 같은 한국어 성능이 뛰어난 소형 언어 모델(sLM)을 구동하기에 충분한 사양입니다. 학생들이 직접 AI 엔진을 구축하고, 이를 활용해 정보처리기사 모의시험 서비스를 만드는 캡스톤 프로젝트 계획을 정리해 드립니다.

[캡스톤 프로젝트] nano-vLLM 기반 한국어 sLM 정보처리기사 학습 플랫폼

1. 프로젝트 개요

- 프로젝트명: "Exam-GPT: nano-vLLM 기반 정처기(정보처리기사) 맞춤형 학습 비서"
 - 핵심 목표: * 고가의 서버 없이 RTX 4070급 로컬 PC에서 고속 추론 엔진(**nano-vLLM**) 구축.
 - 한국어 sLM을 활용하여 정보처리기사 문제 풀이 및 개념 설명 서비스 구현.
 - **PagedAttention** 기술을 직접 적용하여 다수 사용자 혹은 긴 대화의 효율적 처리 경험.
-

2. 시스템 아키텍처 및 기술 스택

- **Hardware:** NVIDIA RTX 4070 (8GB VRAM), 16GB RAM 이상
- **Engine:** nano-vLLM (PagedAttention 기반 초경량 추론 엔진)
- **Model:** * MLP-KTLim/llama-3-Korean-Blossom-8B (4-bit 양자화 권장)
 - yanolja/EEVE-Korean-Instruct-10.8B-v1.0 (VRAM 최적화 필요)

- **Backend:** Python 3.10+, PowerShell 가상환경
- **Frontend:** Gradio (빠른 프로토타이핑을 위한 웹 UI)

3. 단계별 추진 방법 (Milestones)

1단계: 인프라 및 환경 구축 (Week 1-2)

- **Windows** 환경 설정: PowerShell에서 `venv`를 생성하고 CUDA 12.x 기반 PyTorch 설치.
- **vLLM** 최적화: RTX 4070의 8GB 메모리 한계를 극복하기 위해 `bitsandbytes`를 활용한 4-bit 양자화(Quantization) 적용.
- 학습 포인트: "왜 GPU 메모리가 부족한가?"를 계산하며 KV Cache가 차지하는 비중을 수치로 확인.

2단계: 데이터셋 준비 및 RAG 엔진 연동 (Week 3-4)

- 데이터 수집: 정보처리기사 기출문제(JSON/CSV 형태) 및 핵심 요약 PDF 확보.
- **RAG**(검색 증강 생성) 구현: 사용자가 문제를 틀리면, 로컬 벡터 DB(ChromaDB 등)에서 관련 개념을 찾아 sLM이 정확한 해설을 하도록 프롬프트 엔지니어링 수행.

3단계: 웹 서비스 구현 및 최적화 (Week 5-6)

- **API 서버:** nano-vLLM을 FastAPI나 Gradio와 연결하여 실시간 채팅 인터페이스 구축.
- 성능 튜닝: `PagedAttention`의 블록 크기를 조절하며 초당 토큰 생성 수(TPS) 변화 관찰.
- 재미 요소: "오답 노트 생성 기능" 및 "AI 감독관 모드" 추가.

4. 개발 환경 구축 가이드 (요약본)

PowerShell

1. 가상환경 및 권한 설정

```
Set-ExecutionPolicy -ExecutionPolicy RemoteSigned -Scope CurrentUser
```

```
python -m venv capstone_env  
.\capstone_env\Scripts\Activate
```

2. 필수 라이브러리 설치 (RTX 4070 최적화)

```
pip install torch torchvision --index-url https://download.pytorch.org/whl/cu121  
pip install transformers accelerate bitsandbytes gradio
```

3. nano-vLLM 로드 및 한국어 모델 실행 예시

```
# (실제 실행 시 모델 경로와 양자화 설정을 본인 환경에 맞춰 수정)
```

```
python -m nano_vllm.cli --model "Blossom/llama-3-Korean-8B" --gpu-memory-utilization 0.85
```

5. 기대 효과 및 교육적 가치

1. 실무 기술 습득: 현업에서 가장 핫한 **vLLM**과 **sLM** 기술을 로컬 환경에서 깊이 있게 이해함.
2. 비용 절감: OpenAI API 등 유료 모델을 쓰지 않고도 고성능 한국어 AI 서비스를 직접 운영해 보는 경험.
3. 포트폴리오 강화: "단순히 모델을 쓰는 것"을 넘어 "추론 엔진의 효율성(PagedAttention)"을 논할 수 있는 수준의 엔지니어로 성장.