



LLM 기초 이해

3시간 집중 강의

- GPT 구조를 코드로 이해하기 -

오늘의 목표 및 결과물



LLM의 본질

LLM을 "신비한 AI"가 아니라, 수학과 확률에 기반한 **토큰 예측기**로 정확하게 이해합니다.



GPT 구조 이해

현대 AI의 핵심인 **Transformer** 구조를 그림과 논리적 흐름으로 명확하게 설명할 수 있게 됩니다.



코드 실습

실제 파이썬으로 작성된 **microGPT 구현 코드**를 읽고 학습과 생성의 원리를 파악합니다.

Part 1. LLM의 본질

Language Modeling의 정의와 토큰(Token)의 개념 이해

LLM이란 무엇인가?

“ 이전 토큰을 기반으로 다음 토큰의 확률을 예측하는 모델 ”

$$\text{수학적 정의: } P(x_1, \dots, x_n) = \prod P(x_t | x_{<t})$$

방대한 텍스트 데이터를 통해 문법, 의미, 스타일을 통계적으로 압축하여 학습합니다.

다음 단어 예측의 예시

언어 모델은 입력된 텍스트 시퀀스를 분석하여, 다음에 올 수 있는 토큰들의 **확률 분포**를 계산합니다.

Input: "The cat sat on the"

Token	Probability
mat	62.0%
floor	15.0%
chair	8.0%



Part 2. Transformer 구조

RNN의 한계를 넘어선 병렬 처리와 Attention 메커니즘

RNN vs Transformer

Legacy: RNN 구조

과거의 언어 모델은 단어를 하나씩 순서대로 처리했습니다.

- **순차 처리(Sequential):** 병렬 연산이 불가능하여 학습 속도가 매우 느림.
- **장기 의존성 문제:** 문장이 길어지면 앞부분의 정보가 소실됨.

Modern: Transformer 구조

현대의 LLM은 문장 전체를 한 번에 연산합니다.

- **병렬 처리(Parallel):** GPU 자원을 100% 활용하여 압도적인 학습 속도 확보.
- **Attention 매커니즘:** 거리와 상관없이 문맥의 핵심 관계를 파악.

GPT 구조 한 장 요약

GPT는 텍스트 생성에 최적화된 **Decoder-only** 아키텍처를 사용합니다.

1. Token Embedding: 단어를 기계가 이해하는 고차원 숫자 벡터로 변환

2. Positional Encoding: 병렬 처리로 인해 사라진 단어의 순서 (위치) 정보 추가

3. Transformer Blocks: Multi-head Attention과 Feed Forward 연산 반복

4. Linear & Softmax: 최종 벡터를 확률 분포로 변환하여 다음 단어 예측

Self-Attention의 수학적 이해

Attention은 입력된 문장 내에서 어떤 단어가 다른 어떤 단어와 연관성이 높은지 중요도(점수)를 계산하여 가중합을 수행합니다.
(예: "it"이 "animal"을 가리킴을 파악)

$$\text{Attention} (Q , K , V) = \text{softmax} \frac{QK^T}{\sqrt{d_k}} V$$

Q (Query): 내가 찾는 정보

K (Key): 내가 가진 정보의 특징

V (Value): 실제 정보의 내용

Part 3. microGPT 코드 분석

순수 파이썬으로 구현하는 최소한의 GPT 흐름 추적

GPT 학습 및 생성 전체 흐름



1. Tokenize

텍스트 데이터를 문자(Char) 단위로 분리하고 고유 Index(정수)와 매핑합니다.

2. Model

입력 시퀀스를 Embedding하고 Transformer 블록을 통과시켜 Logits를 생성합니다.

3. Train

Cross Entropy Loss를 계산하고 역전파(Backward)를 통해 가중치를 업데이트합니다.

4. Generate

학습된 모델을 기반으로 확률을 샘플링하여 텍스트를 한 글자씩 반복 생성합니다.

Part 4 & 5. 실습 및 응용

파라미터 조절과 LLM의 비즈니스 한계 및 가능성

Temperature가 생성에 미치는 영향

Temperature는 Softmax 함수 실행 전 Logits에 적용되어 출력 확률 분포의 형태를 조절합니다.

설정 (Temperature)	확률 분포 특징	생성 결과	주요 활용 분야
Low (e.g., 0.1)	가장 높은 확률로 극단적으로 치우침	결정적(Deterministic), 일관됨	코드 생성, 데이터 추출, 팩트 기반 질의응답
Medium (e.g., 0.7)	적절한 균형 유지	자연스러운 대화, 적당한 변형	일반적인 챗봇, 이메일 작성 보조
High (e.g., 1.2)	분포가 평탄화(Flatten) 됨	창의적(Creative), 예측 불가능	스토리텔링, 아이디어 브레인 스토밍, 시 작성

주요 LLM 응용 분야 (예상 비중)



LLM은 단순한 텍스트 생성을 넘어, 프로그래밍 보조부터 자율 행동 에이전트까지 다양한 산업의 생산성 자동화 도구로 빠르게 진화하고 있습니다.

오늘의 핵심 요약 (Takeaways)



토큰 예측기

LLM은 사람처럼 생각하는 것이 아니라, 문맥을 기반으로 다음에 올 가장 확률이 높은 토큰을 수학적으로 계산하는 모델입니다.



Self-Attention

Transformer 구조의 핵심으로, 문장 내 모든 단어 간의 상호 연관성을 병렬로 계산하여 깊은 문맥을 파악합니다.



반복적 샘플링

텍스트 생성은 완성된 문장을 한 번에 뱉는 것이 아니라, 예측된 토큰을 입력에 다시 추가(Append)하며 순환하는 과정입니다.

Q&A

수고하셨습니다! 질문이 있으신가요?

다음 단계: API 연동, RAG 아키텍처, Agent 구조 설계

`instructor@llm-academy.edu` | GitHub: `/llm-basics-class`

Image Sources



https://media.istockphoto.com/id/2173858367/vector/yellow-cute-striped-cat-sleeping-curled-on-rug-pixel-art.jpg?s=612x612&w=0&k=20&c=O5TcBvqISvJxnPiE-Mr9E4CqNLVxpJQDOclhOgfOo_o=

Source: www.istockphoto.com



https://images.stockcake.com/public/1/2/5/125bae37-658c-41b2-b9ec-2e8dfc7f8412_large/digital-brain-glows-stockcake.jpg

Source: stockcake.com



https://images.stockcake.com/public/6/2/2/6225fe7a-c636-4bbf-9786-ed5c2991382b_large/neural-network-visualization-stockcake.jpg

Source: stockcake.com